



Python与金融数据挖掘(13)

文欣秀

wenxinxiu@ecust.edu.cn

Python应用领域


科学计算： Numpy、 SciPy...

数据分析： Pandas、 Matplotlib...

机器学习： Scikit-Learn、 Keras...

深度学习： Pytorch、 Mindspore...

...



Tushare简介

Tushare: 是一个**免费、开源**的python财经数据接口包。主要实现对股票等金融数据从**数据采集、清洗加工到数据存储**的过程，能够为金融分析人员提供快速、整洁和多样的便于分析的数据，使他们更加专注于**策略和模型**的研究与实现上。

官网: <https://www.tushare.pro/>

获取数据方法

使用方法： 获取Tushare Pro的数据API，首先需注册一个Pro账号(100积分)，然后登录Pro网站在个人主页里**拿到token码**，修改个人信息(20积分)。对于股票行情数据，只要有120积分就可以相对高频的获取数据。

注册： https://tushare.pro/document/1?doc_id=38

数据接口

```
import tushare as ts
ts.set_token('XXX')    #换成自己的token
pro = ts.pro_api()      #初始化
#获取股票代码为'600000'（浦发银行）的历史行情
df=pro.daily(ts_code='600000.SH', start_date='20220101',
              end_date='20220228')
print(df)
```

数据接口：<https://tushare.pro/document/2>

DataFrame数据选取方法

选取类型	选取方法	说明
基于位置 序号选取	<code>Obj.iloc[iloc, cloc]</code>	选取某行某列
	<code>Obj.iloc[ilocList, clocList]</code>	选取多行多列
	<code>Obj.iloc[a:b, c:d]</code>	选取a~b-1行，
		c~d-1列

存取部分数据

```
import pandas as pd

data=pd.read_csv('data.csv')

print(data. iloc[7,1])

print(data. iloc[[0,2],[1,2]])

result=data.iloc[0:3,1:3]

result.to_csv("result.csv")
```

	A	B	C
1	date	score	price
2	2018/9/3	70	23.55
3	2018/9/4	75	24.43
4	2018/9/5	65	23.41
5	2018/9/6	60	22.81
6	2018/9/7	70	23.21
7	2018/9/10	75	23.46
8	2018/9/11	75	23.34
9	2018/9/12	40	22.88
10	2018/9/13	60	23.1

```
40
      score  price
0         70  23.55
2         65  23.41
```

DataFrame数据选取方法

选取类型	选取方法	说明
基于索引 名选取	Obj[col]	选取某列
	Obj[colList]	选取某几列
	Obj.loc[index,col]	选取某行某列
	Obj.loc[indexList,colList]	选取多行多列

存取部分数据

>>> **pip install openpyxl** #安装第三方库

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group1",index_col=0)  
result=data.loc[[21,23],["Height","Weight"]]  
print(result)  
result.to_excel("result.xlsx")
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	21	female	21	165	45	Shanghai	93	1200
3	22	female	19	167	42	HuBei	89	800
4	23	male	21	169	80	GanSu	93	900
5	24	female	21	160	49	HeBei	59	1100
6	25	female	21	162	54	GanSu	68	1300
7	26	male	21	181	77	SiChuan	62	800
8	27	female	21	162	49	ShanDong	65	950
9	28	female	22	160	52	ShanXi	73	800
10	29	female	20	161	51	GuangXi	80	1250
11	30	female	20	168	52	JiangSu	98	700

DataFrame数据选取方法

选取类型	选取方法	说明
条件筛选	Obj.loc[condition,colList]	使用索引构造条件表达式
	Obj.iloc[condition,clocList]	使用位置序号构造条件表达式

根据年龄统计信息

```
import matplotlib.pyplot as plt
```

```
import pandas as pd
```

```
data=pd.read_excel("info.xlsx","Group1",index_col=0)
```

```
#筛选出年龄大于20岁的学生Sex, Age
```

```
result= data.loc[data['Age'] >20,['Sex','Age']]
```

```
print(result)
```

ID	Sex	Age
21	female	21
23	male	21
24	female	21
25	female	21
26	male	21
27	female	21
28	female	22

Pandas常用统计函数

函数	描述
<code>df.mean()</code>	计算样本数据的算术平均值
<code>df.value_counts()</code>	统计频数
<code>df.describe()</code>	返回基本统计量和分位数
<code>df.corr(sr)</code>	df与sr的相关系数
<code>df.count()</code> 、 <code>df.sum()</code>	统计每列(或行)数据的个数或总和
<code>df.max()</code> 、 <code>df.min()</code>	最大值和最小值
<code>df.idxmax()</code> 、 <code>df.idxmin()</code>	最大值、最小值对应的索引
<code>df.qantile()</code>	计算给定的四分位数
<code>df.var()</code> 、 <code>df.std()</code>	计算方差、标准差
<code>df.mode()</code>	计算众数
<code>df.cov()</code>	计算协方差矩阵

Pandas常用统计案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group1",index_col=0)  
result=data.describe() #对数据进行统计描述  
print(result)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	21	female	21	165	45	Shanghai	93	1200
3	22	female	19	167	42	HuBei	89	800
4	23	male	21	169	80	GanSu	93	900
5	24	female	21	160	49	HeBei	59	1100
6	25	female	21	162	54	GanSu	68	1300
7	26	male	21	181	77	SiChuan	62	800
8	27	female	21	162	49	ShanDong	65	950
9	28	female	22	160	52	ShanXi	73	800
10	29	female	20	161	51	GuangXi	80	1250
11	30	female	20	168	52	JiangSu	98	700

	Age	Height	Weight	Score	Cost
count	10.000000	10.000000	10.0000	10.000000	10.000000
mean	20.700000	165.500000	55.1000	78.000000	980.000000
std	0.823273	6.381397	12.8448	14.476034	216.281709
min	19.000000	160.000000	42.0000	59.000000	700.000000
25%	20.250000	161.250000	49.0000	65.750000	800.000000
50%	21.000000	163.500000	51.5000	76.500000	925.000000
75%	21.000000	167.750000	53.5000	92.000000	1175.000000
max	22.000000	181.000000	80.0000	98.000000	1300.000000

Pandas常用统计函数

函数	描述
<code>df.mean()</code>	计算样本数据的算术平均值
<code>df.value_counts()</code>	统计频数
<code>df.describe()</code>	返回基本统计量和分位数
<code>df.corr(sr)</code>	df与sr的相关系数
<code>df.count()</code> 、 <code>df.sum()</code>	统计每列(或行)数据的个数或总和
<code>df.max()</code> 、 <code>df.min()</code>	最大值和最小值
<code>df.idxmax()</code> 、 <code>df.idxmin()</code>	最大值、最小值对应的索引
<code>df.qantile()</code>	计算给定的四分位数
<code>df.var()</code> 、 <code>df.std()</code>	计算方差、标准差
<code>df.mode()</code>	计算众数
<code>df.cov()</code>	计算协方差矩阵

Pandas常用统计案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group1",index_col=0)  
avg=data['Score'].mean()  
print("成绩的平均值为: {}".format(avg))  
max_age=data['Age'].max()  
print("年龄的最大值为: {}".format(max_age))
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	21	female	21	165	45	Shanghai	93	1200
3	22	female	19	167	42	HuBei	89	800
4	23	male	21	169	80	GanSu	93	900
5	24	female	21	160	49	HeBei	59	1100
6	25	female	21	162	54	GanSu	68	1300
7	26	male	21	181	77	SiChuan	62	800
8	27	female	21	162	49	ShanDong	65	950
9	28	female	22	160	52	ShanXi	73	800
10	29	female	20	161	51	GuangXi	80	1250
11	30	female	20	168	52	JiangSu	98	700

成绩的平均值为: 78.0
年龄的最大值为: 22

Pandas常用统计函数

函数	描述
<code>df.mean()</code>	计算样本数据的算术平均值
<code>df.value_counts()</code>	统计频数
<code>df.describe()</code>	返回基本统计量和分位数
<code>df.corr(sr)</code>	df与sr的相关系数
<code>df.count()</code> 、 <code>df.sum()</code>	统计每列(或行)数据的个数或总和
<code>df.max()</code> 、 <code>df.min()</code>	最大值和最小值
<code>df.idxmax()</code> 、 <code>df.idxmin()</code>	最大值、最小值对应的索引
<code>df.qantile()</code>	计算给定的四分位数
<code>df.var()</code> 、 <code>df.std()</code>	计算方差、标准差
<code>df.mode()</code>	计算众数
<code>df.cov()</code>	计算协方差矩阵

Pandas常用统计案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group1",index_col=0)  
score=data["Score"].sum()  
print("学生的总成绩为: {}".format(score))  
age=data["Age"].mode()  
print("学生多数年龄为: {}".format(age))
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	21	female	21	165	45	Shanghai	93	1200
3	22	female	19	167	42	HuBei	89	800
4	23	male	21	169	80	GanSu	93	900
5	24	female	21	160	49	HeBei	59	1100
6	25	female	21	162	54	GanSu	68	1300
7	26	male	21	181	77	SiChuan	62	800
8	27	female	21	162	49	ShanDong	65	950
9	28	female	22	160	52	ShanXi	73	800
10	29	female	20	161	51	GuangXi	80	1250
11	30	female	20	168	52	JiangSu	98	700

学生的总成绩为: 780
学生多数年龄为: 0 21
Name: Age, dtype: int64

相关性分析

相关性分析：研究现象之间是否存在依赖关系，定量分析可以

通过计算样本之间的相关系数 r 来实现， r 具有以下特征：

1. r 的值介于-1和+1之间， $r=1$ 表示正相关， $r=0$ 表示不相关， $r=-1$ 表示负相关
2. 当 $0<|r|<1$ ，表示两个对象存在一定程度的相关性， $|r|$ 越接近1，关系越密切，越接近0，相关性越弱
3. $|r|<0.4$ 为低相关； $0.4\leq|r|<0.7$ 为中等相关， $|r|\geq 0.7$ 为高相关

Pandas常用统计函数

函数	描述
<code>df.mean()</code>	计算样本数据的算术平均值
<code>df.value_counts()</code>	统计频数
<code>df.describe()</code>	返回基本统计量和分位数
<code>df.corr(sr)</code>	<code>df</code> 与 <code>sr</code> 的相关系数
<code>df.count()</code> 、 <code>df.sum()</code>	统计每列(或行)数据的个数或总和
<code>df.max()</code> 、 <code>df.min()</code>	最大值和最小值
<code>df.idxmax()</code> 、 <code>df.idxmin()</code>	最大值、最小值对应的索引
<code>df.qantile()</code>	计算给定的四分位数
<code>df.var()</code> 、 <code>df.std()</code>	计算方差、标准差
<code>df.mode()</code>	计算众数
<code>df.cov()</code>	计算协方差矩阵

Pandas常用统计案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group1",index_col=0)  
result=data['Height'].corr( data['Weight'] )  
print("身高和体重的相关性为: {}".format(result))
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	21	female	21	165	45	Shanghai	93	1200
3	22	female	19	167	42	HuBei	89	800
4	23	male	21	169	80	GanSu	93	900
5	24	female	21	160	49	HeBei	59	1100
6	25	female	21	162	54	GanSu	68	1300
7	26	male	21	181	77	SiChuan	62	800
8	27	female	21	162	49	ShanDong	65	950
9	28	female	22	160	52	ShanXi	73	800
10	29	female	20	161	51	GuangXi	80	1250
11	30	female	20	168	52	JiangSu	98	700

身高和体重的相关性为: 0.6757399098527682

Pandas常用统计案例

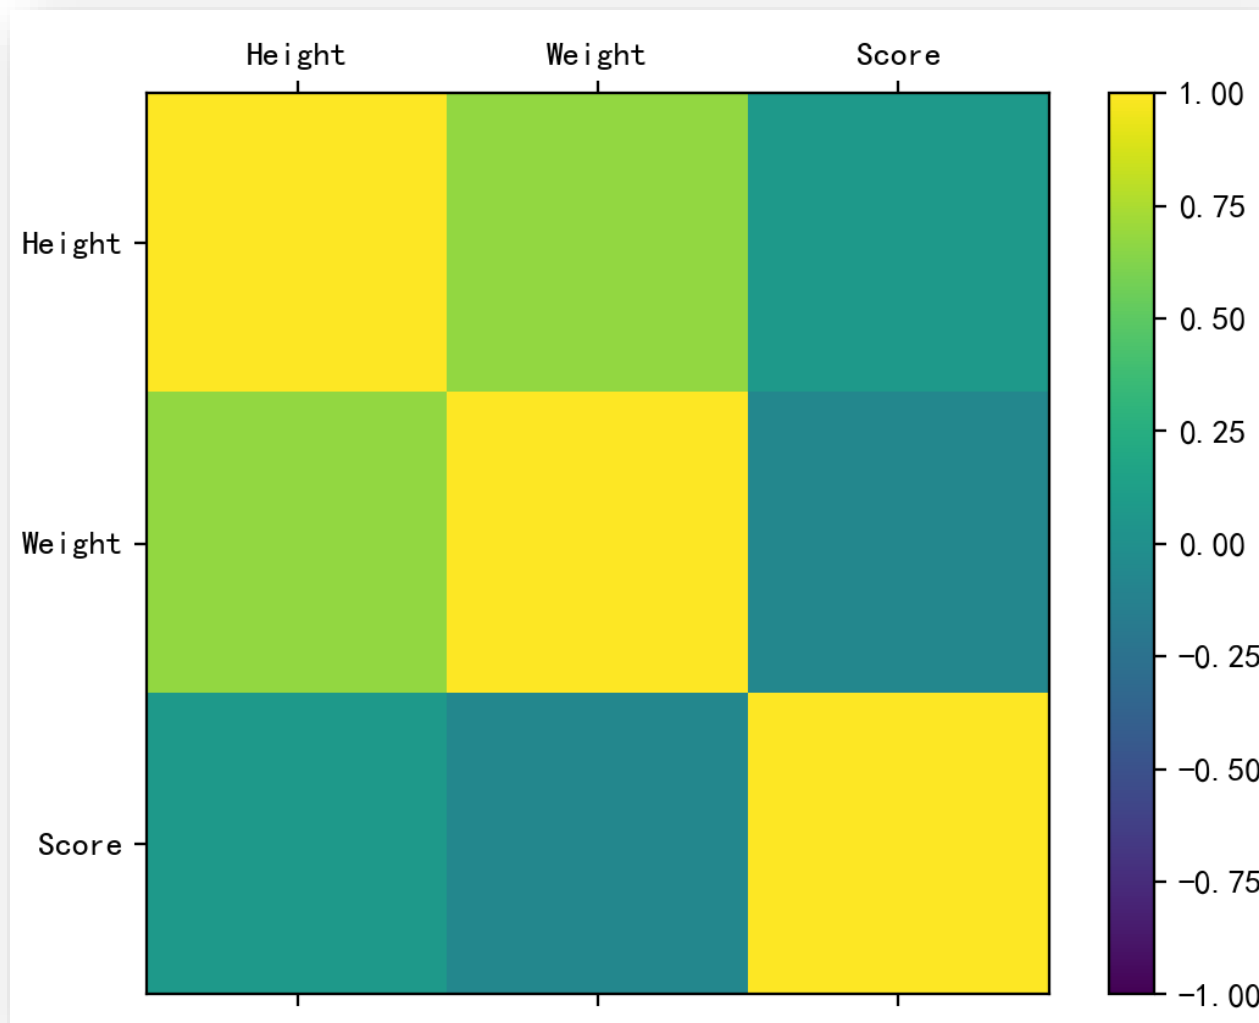
```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group1",index_col=0)  
result=data[['Height','Weight','Score'] ].corr()  
print(result)
```

如果想画图显示三者关系如何处理？

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	21	female	21	165	45	Shanghai	93	1200
3	22	female	19	167	42	HuBei	89	800
4	23	male	21	169	80	GanSu	93	900
5	24	female	21	160	49	HeBei	59	1100
6	25	female	21	162	54	GanSu	68	1300
7	26	male	21	181	77	SiChuan	62	800
8	27	female	21	162	49	ShanDong	65	950
9	28	female	22	160	52	ShanXi	73	800
10	29	female	20	161	51	GuangXi	80	1250
11	30	female	20	168	52	JiangSu	98	700


	Height	Weight	Score
Height	1.000000	0.675740	0.080587
Weight	0.675740	1.000000	-0.072305
Score	0.080587	-0.072305	1.000000

Matshow图




Pandas统计分析案例

```
import matplotlib.pyplot as plt #导入matplotlib.pyplot
import pandas as pd
plt.rcParams['font.family']=['SimHei']
data=pd.read_excel("info.xlsx","Group1",index_col=0)
result=data[['Height','Weight','Score'] ].corr()
plt.matshow(result) #相关矩阵图展示两个不同属性相互影响的程度
plt.show()
```



Pandas统计分析案例（拓展）

```
import matplotlib.pyplot as plt #导入matplotlib.pyplot
import pandas as pd
import numpy as np
```



```
#plt.rcParams['font.family']='SimHei' #显示中文
```


```
plt.rcParams['axes.unicode_minus'] = False #显示负号
```

```
data=pd.read_excel("info.xlsx","Group1",index_col=0)
```

```
result=data[['Height','Weight','Score']].corr()
```


Pandas统计分析案例 (拓展)

```
fig=plt.figure()
ax=fig.add_subplot(111)
cax=ax.matshow(result, vmin=-1, vmax=1) #相关矩阵图
fig.colorbar(cax)
ticks=np.arange(0,3,1)
names=['Height','Weight','Score']
ax.set_xticks(ticks); ax.set_yticks(ticks)
ax.set_xticklabels(names); ax.set_yticklabels(names)
plt.show()
```



数据规整化

	A		A	B	C	D		A	B	C
1	ID	1	ID	Sex	Age	Height	1	ID	Interest	Case teaching
2	21	2	31	female	21	162	2	21	5	5
3	22	3	32	female	20	162	3	22	5	5
4	23	4	33	male	20	171	4	23	5	5
5	24	5	34	male	21	172	5	24	3	5
6	25	6	35	male	20	171	6	32	4	5
7	26	7	36	male	21	174	7	34	2	5
8	27	8	37	male	21	177	8	27	4	4
9	28	9	38	male	19	170	9	28	3	4
10	29	10	39	female	19	159	10	29	5	5
11	30	11	40	female	21	163	11	30	5	5

数据规整化

➤ **concat()**: 行数据连接函数

```
import pandas as pd  
data1=pd.read_excel("info.xlsx","Group1",index_col=0)  
data2=pd.read_excel("info.xlsx","Group3",index_col=0)
```

#axis=0表示按行追加

```
data = pd.concat([data1,data2], axis=0)  
print(data)
```

ID	Sex	Age	Height	Weight	Province	Score	Cost
21	female	21	165	45	Shanghai	93	1200
22	female	19	167	42	HuBei	89	800
23	male	21	169	80	GanSu	93	900
24	female	21	160	49	HeBei	59	1100
25	female	21	162	54	GanSu	68	1300
26	male	21	181	77	SiChuan	62	800
27	female	21	162	49	ShanDong	65	950
28	female	22	160	52	ShanXi	73	800
29	female	20	161	51	GuangXi	80	1250
30	female	20	168	52	JiangSu	98	700
31	female	21	162	45	JiLin	92	1400
32	female	20	162	45	ChongQing	63	650
33	male	20	171	64	JiangXi	77	1300
34	male	21	172	78	BeiJing	62	950
35	male	20	171	66	ShangHai	97	650
36	male	21	174	78	GanSu	87	1300
37	male	21	177	68	XinJiang	95	500
38	male	19	170	79	YunNan	63	1000
39	female	19	159	46	ShanDong	64	1100
40	female	21	163	52	JiangXi	62	1500

数据规整化

➤ `merge(x,y,how,left_on,right_on...)`

x: 左数据对象

y: 右数据对象

how: 数据对象连接方式: inner, outer, left, right

- **inner:** 内连接, 连接两个数据对象中键值交集的行
- **left:** 左连接, 取出x的全部行, 连接y中匹配的键值行

left_on: 左数据用于连接的键

right_on: 右数据用于连接的键

数据规整化

➤ merge(): 列数据连接函数

```
import pandas as pd
data1=pd.read_excel("info.xlsx","Group1",index_col=0)
data2=pd.read_excel("info.xlsx","Group4",index_col=0)
result= pd.merge(data1,data2, how='left',left_on="ID",right_on="ID")
```

print(result) #左连接

ID	Sex	Age	Height	Weight	...	Score	Cost	Interest	Case teaching
21	female	21	165	45	...	93	1200	5.0	5.0
22	female	19	167	42	...	89	800	5.0	5.0
23	male	21	169	80	...	93	900	5.0	5.0
24	female	21	160	49	...	59	1100	3.0	5.0
25	female	21	162	54	...	68	1300	NaN	NaN
26	male	21	181	77	...	62	800	NaN	NaN
27	female	21	162	49	...	65	950	4.0	4.0
28	female	22	160	52	...	73	800	3.0	4.0
29	female	20	161	51	...	80	1250	5.0	5.0
30	female	20	168	52	...	98	700	5.0	5.0

[10 rows x 9 columns]

数据排序

➤ 按索引排序

```
import pandas as pd
data=pd.read_excel("info.xlsx","Group1",index_col=0)
#按行索引降序排序
result1=data.sort_index(ascending=False)
print(result1)
```

	ID	Sex	Age	Height	Weight	Province	Score	Cost
	30	female	20	168	52	JiangSu	98	700
	29	female	20	161	51	GuangXi	80	1250
	28	female	22	160	52	ShanXi	73	800
	27	female	21	162	49	ShanDong	65	950
	26	male	21	181	77	SiChuan	62	800
	25	female	21	162	54	GanSu	68	1300
	24	female	21	160	49	HeBei	59	1100
	23	male	21	169	80	GanSu	93	900
	22	female	19	167	42	HuBei	89	800
	21	female	21	165	45	Shanghai	93	1200

数据排序

➤ 按值排序

```
import pandas as pd
data=pd.read_excel("info.xlsx","Group1",index_col=0)
result2=data.sort_values(by='Score', ascending=False)
print(result2)
result3=data.sort_values(by=['Height','Weight'], ascending=True)
print(result3)
```

ID	Sex	Age	Height	Weight	Province	Score	Cost	ID	Sex	Age	Height	Weight	Province	Score	Cost
30	female	20	168	52	JiangSu	98	700	24	female	21	160	49	HeBei	59	1100
21	female	21	165	45	Shanghai	93	1200	28	female	22	160	52	ShanXi	73	800
23	male	21	169	80	GanSu	93	900	29	female	20	161	51	GuangXi	80	1250
22	female	19	167	42	HuBei	89	800	27	female	21	162	49	ShanDong	65	950
29	female	20	161	51	GuangXi	80	1250	25	female	21	162	54	GanSu	68	1300
28	female	22	160	52	ShanXi	73	800	21	female	21	165	45	Shanghai	93	1200
25	female	21	162	54	GanSu	68	1300	22	female	19	167	42	HuBei	89	800
27	female	21	162	49	ShanDong	65	950	30	female	20	168	52	JiangSu	98	700
26	male	21	181	77	SiChuan	62	800	23	male	21	169	80	GanSu	93	900
24	female	21	160	49	HeBei	59	1100	26	male	21	181	77	SiChuan	62	800

DataFrame数据排序

➤ 排名

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group1",index_col=0)  
#对成绩数据降序排名，增加“排名”列,method为并列名次取值  
#比如（2，3名成绩相同，min取2,max取3）  
data['Rank'] = data['Score'].rank(method='min', ascending=False)  
print( data )
```

ID	Sex	Age	Height	Weight	Province	Score	Cost	Rank
21	female	21	165	45	Shanghai	93	1200	2.0
22	female	19	167	42	HuBei	89	800	4.0
23	male	21	169	80	GanSu	93	900	2.0
24	female	21	160	49	HeBei	59	1100	10.0
25	female	21	162	54	GanSu	68	1300	7.0
26	male	21	181	77	SiChuan	62	800	9.0
27	female	21	162	49	ShanDong	65	950	8.0
28	female	22	160	52	ShanXi	73	800	6.0
29	female	20	161	51	GuangXi	80	1250	5.0
30	female	20	168	52	JiangSu	98	700	1.0

数据清洗

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

数据清洗

数据清洗：对采集的数据进行重新审查和校验的过程，其目的在于删除重复信息、纠正存在的错误，保证数据的一致性。

常见问题：

- 数据缺失
- 数据重复
- 数据不一致

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

数据清洗

丢弃缺失值 `dropna(axis, how, thresh, ...)`

axis: 0表示按行滤除，1表示按列滤除，默认为axis=0

`data.dropna()` #每行只要有空值，就将该行删除

`data.dropna(axis=1)` #每列只要有空值，就将该列删除

数据清洗案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group2",index_col=0)  
data1=data.dropna() #默认按行删除  
print(data1)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

	Sex	Age	Height	Weight	Province	Score	Cost
ID							
2.0	male	22.0	180.0	71.0	GuangXi	77.0	1300.0
4.0	male	20.0	177.0	72.0	LiaoNing	79.0	900.0
6.0	male	20.0	179.0	75.0	YunNan	92.0	950.0
7.0	female	21.0	166.0	53.0	LiaoNing	80.0	1200.0
8.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
9.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
10.0	male	120.0	169.0	76.0	HeiLongJiang	88.0	1100.0

数据清洗案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group2",index_col=0)  
data1=data.dropna(axis=1) #按列删除  
print(data1)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

Empty DataFrame

Columns: []

Index: [1.0, 2.0, 3.0, 4.0, 5.0, 6.0, nan, 7.0, 8.0, 9.0, 10.0]

数据清洗

丢弃缺失值`dropna(axis,how,thresh,...)`

how: "all"表示滤除全部值都为NaN的行或列

`data.dropna(how='all')` #一行中全部为NaN才丢弃该行

数据清洗案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group2",index_col=0)  
data1=data.dropna(how="all") #一行全部为NaN才删  
print(data1)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

	Sex	Age	Height	Weight	Province	Score	Cost
ID							
1.0	male	20.0	170.0	70.0	LiaoNing	NaN	800.0
2.0	male	22.0	180.0	71.0	GuangXi	77.0	1300.0
3.0	male	NaN	180.0	62.0	FuJian	57.0	1000.0
4.0	male	20.0	177.0	72.0	LiaoNing	79.0	900.0
5.0	male	20.0	172.0	NaN	ShanDong	91.0	NaN
6.0	male	20.0	179.0	75.0	YunNan	92.0	950.0
7.0	female	21.0	166.0	53.0	LiaoNing	80.0	1200.0
8.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
9.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
10.0	male	120.0	169.0	76.0	HeiLongJiang	88.0	1100.0

数据清洗

丢弃缺失值 `dropna(axis, how, thresh, ...)`

thresh: 只留下有效数据数大于或等于thresh的行或列

`data.dropna(thresh=6)` # 每行至少6个非空值才保留

数据清洗案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group2",index_col=0)  
data1=data.dropna(thresh=6) # 每行至少6个非空值才保留  
print(data1)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

ID	Sex	Age	Height	Weight	Province	Score	Cost
1.0	male	20.0	170.0	70.0	LiaoNing	NaN	800.0
2.0	male	22.0	180.0	71.0	GuangXi	77.0	1300.0
3.0	male	NaN	180.0	62.0	FuJian	57.0	1000.0
4.0	male	20.0	177.0	72.0	LiaoNing	79.0	900.0
6.0	male	20.0	179.0	75.0	YunNan	92.0	950.0
7.0	female	21.0	166.0	53.0	LiaoNing	80.0	1200.0
8.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
9.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
10.0	male	120.0	169.0	76.0	HeiLongJiang	88.0	1100.0

数据清洗

缺失值填充 `fillna(value, method,...)`

value: 填充值，可以是标量、字典等

`data.fillna(0)` #用0填充

数据清洗案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group2",index_col=0)  
data1=data.fillna(0) #用0填充  
print(data1)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

ID	Sex	Age	Height	Weight	Province	Score	Cost
1.0	male	20.0	170.0	70.0	LiaoNing	0.0	800.0
2.0	male	22.0	180.0	71.0	GuangXi	77.0	1300.0
3.0	male	0.0	180.0	62.0	FuJian	57.0	1000.0
4.0	male	20.0	177.0	72.0	LiaoNing	79.0	900.0
5.0	male	20.0	172.0	0.0	ShanDong	91.0	0.0
6.0	male	20.0	179.0	75.0	YunNan	92.0	950.0
NaN	0	0.0	0.0	0.0	0	0.0	0.0
7.0	female	21.0	166.0	53.0	LiaoNing	80.0	1200.0
8.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
9.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
10.0	male	120.0	169.0	76.0	HeiLongJiang	88.0	1100.0

数据清洗

缺失值填充`fillna(value, method,...)`

value: 填充值，可以是标量、字典等

```
data.fillna({'Age': data['Age'].mean(), 'Sex': 'male'})
```

数据清洗案例

```
import pandas as pd

data=pd.read_excel("info.xlsx","Group2",index_col=0)

data1=data. fillna({'Age': data['Age'].mean(), 'Sex': 'male'})

print(data1)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

	Sex	Age	Height	Weight	Province	Score	Cost
ID							
1.0	male	20.000000	170.0	70.0	LiaoNing	NaN	800.0
2.0	male	22.000000	180.0	71.0	GuangXi	77.0	1300.0
3.0	male	31.444444	180.0	62.0	FuJian	57.0	1000.0
4.0	male	20.000000	177.0	72.0	LiaoNing	79.0	900.0
5.0	male	20.000000	172.0	NaN	ShanDong	91.0	NaN
6.0	male	20.000000	179.0	75.0	YunNan	92.0	950.0
NaN	male	31.444444	NaN	NaN	NaN	NaN	NaN
7.0	female	21.000000	166.0	53.0	LiaoNing	80.0	1200.0
8.0	female	20.000000	162.0	47.0	AnHui	78.0	1000.0
9.0	female	20.000000	162.0	47.0	AnHui	78.0	1000.0
10.0	male	120.000000	169.0	76.0	HeiLongJiang	88.0	1100.0

数据清洗

缺失值填充**ffill()**、**bfill()**

`data. ffill()` #在列方向上以上一个值替换

`data. bfill()` #在列方向上以下一个值替换

数据清洗案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group2",index_col=0)  
data1=data. ffill() #在列方向上以上一个值替换  
print(data1)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

	Sex	Age	Height	Weight	Province	Score	Cost
ID							
1.0	male	20.0	170.0	70.0	LiaoNing	NaN	800.0
2.0	male	22.0	180.0	71.0	GuangXi	77.0	1300.0
3.0	male	22.0	180.0	62.0	FuJian	57.0	1000.0
4.0	male	20.0	177.0	72.0	LiaoNing	79.0	900.0
5.0	male	20.0	172.0	72.0	ShanDong	91.0	900.0
6.0	male	20.0	179.0	75.0	YunNan	92.0	950.0
NaN	male	20.0	179.0	75.0	YunNan	92.0	950.0
7.0	female	21.0	166.0	53.0	LiaoNing	80.0	1200.0
8.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
9.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
10.0	male	120.0	169.0	76.0	HeiLongJiang	88.0	1100.0

数据清洗

值替换 `replace(to_replace, value, ...)`

to_replace: 将被替代的值

value: 替换为的值

`data['Age'].replace(120, 20)` #将年龄120替换为20

数据清洗案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group2",index_col=0)  
data['Age'].replace(120, 20,inplace=True) #将年龄120替换为20  
print(data)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

ID	Sex	Age	Height	Weight	Province	Score	Cost
1.0	male	20.0	170.0	70.0	LiaoNing	NaN	800.0
2.0	male	22.0	180.0	71.0	GuangXi	77.0	1300.0
3.0	male	NaN	180.0	62.0	FuJian	57.0	1000.0
4.0	male	20.0	177.0	72.0	LiaoNing	79.0	900.0
5.0	male	20.0	172.0	NaN	ShanDong	91.0	NaN
6.0	male	20.0	179.0	75.0	YunNan	92.0	950.0
NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7.0	female	21.0	166.0	53.0	LiaoNing	80.0	1200.0
8.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
9.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
10.0	male	20.0	169.0	76.0	HeiLongJiang	88.0	1100.0

数据清洗

去掉重复值 `drop_duplicates()`

`data.drop_duplicates()` #去掉重复的数据

数据清洗案例

```
import pandas as pd  
data=pd.read_excel("info.xlsx","Group2",index_col=0)  
data1=data.drop_duplicates() #去掉重复的数据  
print(data1)
```

	A	B	C	D	E	F	G	H
1	ID	Sex	Age	Height	Weight	Province	Score	Cost
2	1	male	20	170	70	LiaoNing		800
3	2	male	22	180	71	GuangXi	77	1300
4	3	male		180	62	FuJian	57	1000
5	4	male	20	177	72	LiaoNing	79	900
6	5	male	20	172		ShanDong	91	
7	6	male	20	179	75	YunNan	92	950
8								
9	7	female	21	166	53	LiaoNing	80	1200
10	8	female	20	162	47	AnHui	78	1000
11	9	female	20	162	47	AnHui	78	1000
12	10	male	120	169	76	HeiLongJiang	88	1100

	Sex	Age	Height	Weight	Province	Score	Cost
ID							
1.0	male	20.0	170.0	70.0	LiaoNing	NaN	800.0
2.0	male	22.0	180.0	71.0	GuangXi	77.0	1300.0
3.0	male	NaN	180.0	62.0	FuJian	57.0	1000.0
4.0	male	20.0	177.0	72.0	LiaoNing	79.0	900.0
5.0	male	20.0	172.0	NaN	ShanDong	91.0	NaN
6.0	male	20.0	179.0	75.0	YunNan	92.0	950.0
NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7.0	female	21.0	166.0	53.0	LiaoNing	80.0	1200.0
8.0	female	20.0	162.0	47.0	AnHui	78.0	1000.0
10.0	male	120.0	169.0	76.0	HeiLongJiang	88.0	1100.0

常用数据挖掘算法

关联分析： 旨在找出所有能把一组事件或数据项与另一组事件或数据项联系起来的强关联规则（拉关系）。**Apriori**算法是典型的关联分析算法。

例如，如果你今天在淘宝或京东等大型电商平台购买了手机，那么你明天登录网站的时候，很可能会购买手机套、数据线等和手机使用相关的产品。

常用数据挖掘算法

数据分类：分类是指通过对数据集的学习获得一个映射函数，从而将未知类别的样本映射到给定类别中（贴标签）。分类算法通常包括训练（即生成分类函数）和识别（即样品归类）两个阶段，典型的分类算法包括**决策树、贝叶斯、神经网络、支持向量机等**。

例如，在银行的历史信用卡数据中，有按时还款的正常客户，也有不能按时还款的逾期客户。银行希望通过用户的基础信息及历史交易数据等，判断其是正常客户还是逾期客户（这个就是分类标签），从而提前甄别出逾期客户，以尽可能地降低逾期发生率。

常用数据挖掘算法

数据聚类： 聚类旨在将数据集内具有相似特征的数据聚集成簇，从而使得同一个簇的数据特征尽可能相似，不同簇中的数据特征有明显的区别（找朋友）。典型的聚类算法包括**K均值聚类**、**K中心点**、**神经网络聚类**算法等。

聚类和分类算法的区别在于：分类任务中的训练数据集是有标签的，比方说正常/逾期，好/坏，Yes/No等，而聚类任务中的数据集则没有标签，只是根据特征的相似性将数据集聚集成不同的簇。比方说携程、去哪儿就会根据用户历史消费记录进行用户画像，总结出某一群体的共性，从而决定推荐的住宿酒店的档次、位置等属性。

常用数据挖掘算法

时间序列分析： 是根据数据过去和现在的变化规律去预测未来发展趋势的一种数据分析技术（测未来）。时间序列分析任务一般是针对那些与时间变化相关的指标，算法的目标是发现它随时间变化的趋势，从而能够进行预测。

在金融相关的宏观经济运行研究和管理工作中，经常要使用这时间序列分析来预测国民生产总值**GDP**，消费价格指数**CPI**等指标的变动情况。常见的时间序列分析算法主要包括简单移动平均、复杂差分整合移动平均、自回归等。

案例分析

以信用卡申请核发的业务为例，银行已经积累了大量客户的申请信息、消费记录和是否正常还款的历史数据，现在想以这些数据为基础，研发一套数据挖掘系统，用于在核准新用户申请办理信用卡期间的决策支持。



案例分析

1. 流程转化：将人工核准流程转换为计算机的处理流程。

招商银行信用卡评分一览表(总分：100分=27+15+34+24)						
稳定性 27分	婚姻	未婚(2)	已婚无子女(3)	已婚有子女(4)		
	居住	2年以下(2)	2-6年(5)	6年以上(7)		
	从业	公务员(16)	国有企业(13)	失业无社会救济(8)		其他(4)
		事业单位(14)	股份制企业(10)	失业有社会救济(10)	退休(16)	
房产 15分	住房	无房(0)	租房(2)	单位福利分房(4)	所有或购买(8)	
	抵押	无抵押(7)	有抵押(0)			
收支 34分	收入	6千元/月(26)	3千-6千(22)	2千-3千(18)	1千-2千(13)	3百-1千(7)
	偿债	无债务(8)	10-100元(6)	100-500(4)	500以上(2)	
个人背景 24分	户籍	本地(5)	外地(2)			
	文化程度	初中及初中以下(1)	高中(2)	中专(4)	大专以上(5)	
	年龄	女30岁以下(3)	女30岁以上(5)	男30岁以下(2.5)	男30岁以上(4.5)	
	失信	未调查、无记录(0)	一次失信(0)	两次以上(-9)	无	

案例分析

2. 选择算法：这是一个典型的分类问题，训练数据中的标签是正常还款和逾期还款，特征为用户还款的信息。希望能够使用老用户的申请信息来预测一个新客户是否会按时还款。

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	姓名	婚姻	居住	从业	住房	抵押	收入	偿债	户籍	文化程度	年龄	失信	标签
2	张三	4	5	16	4	7	22	8	5	5	4.5	0	正常还款
3	李雪	3	6	13	4	7	26	8	5	5	5	0	正常还款
4	李飞飞	2	2	8	2	0	7	8	5	1	2.5	0	逾期还款

案例分析

- 3. 模型的训练：** 将历史数据处理成算法能接受的数据格式后输入到算法中，生成预测函数。算法的输入数据是用户的申请信息或消费记录，输出结果是正常还款或逾期还款。
- 4. 调整参数：** 调整预测函数的参数，优化预测性能。
- 5. 模型预测：** 将预测函数用于后期预测，输入新用户信息，获得预测结果，即正常还款或逾期还款。

Python应用领域

文本分析：Jieba、Nltk...

科学计算：Numpy、SciPy...

数据分析：Pandas、Matplotlib...


机器学习：Scikit-Learn、Keras...

深度学习：Pytorch、Mindspore...

scikit-learn

scikit-learn: 基于NumPy, SciPy, matplotlib, 可以实现数据预处理、分类、回归、降维、聚类、模型选择等常用的机器学习算法, 是数据挖掘和数据分析的一个简单有效工具。

机器学习分类: 有监督学习、无监督学习



谢 谢